Elosztott rendszerek: Alapelvek és paradigmák Distributed Systems: Principles and Paradigms

Maarten van Steen¹ Kitlei Róbert ²

¹VU Amsterdam, Dept. Computer Science ²ELTE Informatikai Kar

2. rész: Architektúrák

2015. május 24.

Tartalomjegyzék

Fejezet	
01: Bevezetés	
02: Architektúrák	
03: Folyamatok	
04: Kommunikáció	
05: Elnevezési rendszerek	
06: Szinkronizáció	
07: Konzisztencia & replikáció	
08: Hibatűrés	
10: Objektumalapú elosztott rendszerek	
11: Elosztott fájlrendszerek	
12: Elosztott webalapú rendszerek	
	_

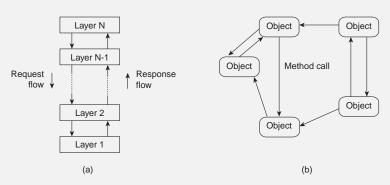
Architektúrák

- Architektúrafajták
- Szoftverarchitektúrák
- Architektúrák és köztesréteg
- Az elosztott rendszerek önszervezése

Architektúrafajták

Alapötlet

A rendszer elemeit szervezzük logikai szerepük szerint különböző komponensekbe, és ezeket osszuk el a rendszer gépein.

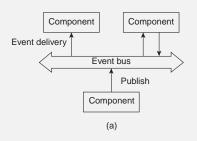


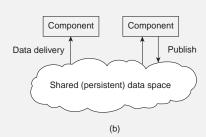
- (a) A többrétegű megközelítés kliens-szerver rendszerek esetén jól működik
- (b) Itt a komponensek (objektumok) összetettebb struktúrában kommunikálnak, mindegyik közvetlenül küld üzeneteket a többieknek.

Architektúrafajták

További architektúrafajták

A komponensek közötti kommunikáció történhet közvetlen kapcsolat nélkül ("anonim"), illetve egyidejűség nélkül ("aszinkron").





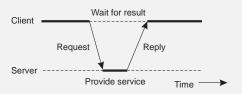
- (a) Publish/subscribe modell (térben független)
- (b) Megosztott, perzisztens adattár (térben és időben független)

Központosított architektúrák

Egyszerű kliens-szerver modell

Jellemzői:

- egyes folyamatok szolgáltatásokat ajánlanak ki (ezek a szerverek)
- más folyamatok ezeket a szolgáltatásokat szeretnék használni (ezek a kliensek)
- a kliensek és a szerverek különböző gépeken lehetnek
- a kliens kérést küld (amire a szerver válaszol), így veszi igénybe a szolgáltatást



Többrétegű architektúrák

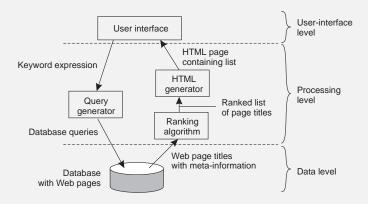
Elosztott információs rendszerek rétegelése

Az elosztott információs rendszerek gyakran három logikai rétegre ("layer" vagy "tier") vannak tagolva.

Háromrétegű architektúra

- Megjelenítés (user interface): az alkalmazás felhasználói felületét alkotó komponensekből áll
- Üzleti logika (application): az alkalmazás működését írja le (konkrét adatok nélkül)
- Perzisztencia (data layer): az adatok tartós tárolása

Többrétegű architektúrák

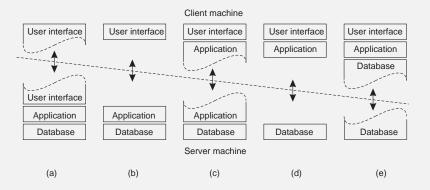


Többrétegű architektúrák

A három rétegből néha több is egy gépen található meg.

Kétrétegű architektúra: kliens/egyszerű szerver Egyrétegű architektúra: nagygépre (mainframe) kötött terminál

A kétrétegű architektúra többféleképpen bonthatja fel a három réteget:



Decentralizált architektúrák

Peer-to-peer architektúra

Az utóbbi években a peer-to-peer (P2P) architektúra egyre népszerűbbé válik. A "peer" szó arra utal, hogy a csúcsok között (többnyire) nincsenek kitüntetett szerepűek.

- strukturált P2P: a csúcsok által kiadott gráfszerkezet rögzített
- strukturálatlan P2P: a csúcsok szomszédai véletlenszerűek
- hibrid P2P: néhány csúcsnak speciális szerepe van, ezek a többitől eltérő szervezésűek

Overlay hálózat

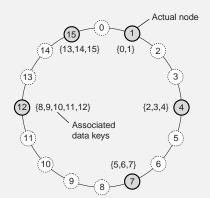
overlay: A gráfban szomszédos csúcsok a fizikai hálózaton lehetnek távol egymástól, a rendszer elfedi, hogy a köztük levő kommunikáció több gépet érintve történik.

A legtöbb P2P rendszer overlay hálózatra épül.

Strukturált P2P rendszerek

Alapötlet

A csúcsokat valamilyen struktúra szerint overlay hálózatba szervezzük (pl. logikai gyűrű), és a csúcsoktól az azonosítójuk alapján lehet szolgáltatásokat igénybe venni.



Példa: elosztott hasítótábla

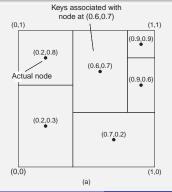
Ebben a rendszerben kulcs-érték párokat tárolunk.

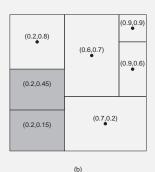
Az adott értéket tároló csúcsot hatékonyan meg lehet keresni a kulcsa alapján, akármelyik csúcsra is érkezik be a kérés.

Strukturált P2P rendszerek

Példa: d dimenziós particionált tér

Az adatoknak most *d* mezője van, kulccsal nem rendelkeznek. Az így adódó tér fel van osztva annyi tartományra, ahány csúcsunk van; minden csúcs valamelyik tartomány adataiért felelős. Ha egy új csúcs érkezik, kettébontunk egy tartományt.





Strukturálatlan P2P rendszerek

Strukturálatlan P2P rendszer

A strukturálatlan P2P rendszerek igyekeznek véletlen gráfstruktúrát fenntartani.

- Mindegyik csúcsnak csak részleges nézete van a gráfról (a teljes hálózatnak csak egy kis részét látja).
- Minden P csúcs időközönként kiválaszt egy szomszédos Q csúcsot
- P és Q információt cserél, valamint átküldik egymásnak az általuk ismert csúcsokat

Megjegyzés

A rendszer hibatűrését és a gráf véletlenszerűségét nagyban befolyásolja az, hogy a harmadik lépésben pontosan milyen adatok kerülnek át.

Aktív szál

```
selectPeer(&B);
selectToSend(&bufs);
sendTo(B, bufs);
receiveFrom(B, &bufr);
selectToKeep(cache, bufr);
```

Passzív szál

```
receiveFromAny(&A, &bufr);
selectToSend(&bufs);
sendTo(A, bufs);
selectToKeep(cache, bufr);
```

selectToSend: Az általa ismert szomszédok közül kiválaszt *n* darabot selectToKeep: (1) A megkapott csúcsokat eltárolja lokálisan.
(2) Eltávolítja a többszörösen szereplő csúcsokat.
(3) A tárolt csúcsok számát *m* darabra csökkenti. Erre többfaita stratégia lehetséges.

Aktív szál selectPeer (&B); selectToSend (&bufs); sendTo (B, bufs); receiveFrom (B, &bufr);

Passzív szál

```
receiveFromAny(&A, &bufr);
selectToSend(&bufs);
sendTo(A, bufs);
selectToKeep(cache, bufr);
```

selectPeer: A részleges nézetből kiválaszt egy szomszédot.

selectToSend: Az általa ismert szomszédok közül kiválaszt n dara

- selectToKeep:
- (1) A megkapott csúcsokat eltárolia lokálisan.
- (2) El+
 - 2) Eltávolítia a többszörösen szereplő csúcsokat.
 - (3) A tárolt csúcsok számát m darabra csökkenti. Erre
 - többfajta stratégia lehetséges

Aktív szál selectPeer(&B); selectToSend(&bufs); sendTo(B, bufs); receiveFrom(B, &bufr); selectToKeep(cache, bufr);

Passzív szál

```
receiveFromAny(&A, &bufr);
selectToSend(&bufs);
sendTo(A, bufs);
selectToKeep(cache, bufr);
```

selectPeer: A részleges nézetből kiválaszt egy szomszédot.

selectToSend: Az általa ismert szomszédok közül kiválaszt n darabot.

- (1) A megkanott csúcsokat eltárolia lokálisan
- (2) Eltávolítia a többszörösen szereplő csúcsokat.
- (3) A tárolt csúcsok számát *m* darabra csökkenti. Erre

```
Aktív szál

selectPeer(&B);

selectToSend(&bufs);

sendTo(B, bufs);

receiveFrom(B, &bufr);

selectToKeep(cache, bufr);
```

Passzív szál

```
receiveFromAny(&A, &bufr);
selectToSend(&bufs);
sendTo(A, bufs);
selectToKeep(cache, bufr);
```

selectPeer: A részleges nézetből kiválaszt egy szomszédot.

selectToSend: Az általa ismert szomszédok közül kiválaszt n darabot.

- (1) A megkanott csúcsokat eltárolia lokálisan
- (2) Eltávolítia a többszörösen szereplő csúcsokat.
- (3) A tárolt csúcsok számát *m* darabra csökkenti. Erre

```
Aktív szál

selectPeer(&B);

selectToSend(&bufs);

sendTo(B, bufs);

receiveFrom(B, &bufr);

selectToKeep(cache, bufr);
```

Passzív szál

```
receiveFromAny(&A, &bufr);
selectToSend(&bufs);
sendTo(A, bufs);
selectToKeep(cache, bufr);
```

selectPeer: A részleges nézetből kiválaszt egy szomszédot.

selectToSend: Az általa ismert szomszédok közül kiválaszt n darabot.

- (1) A megkanott csúcsokat eltárolia lokálisan
- (2) Eltávolítia a többszörösen szereplő csúcsokat.
- (3) A tárolt csúcsok számát *m* darabra csökkenti. Erre

```
Aktív szál
selectPeer(&B);
selectToSend(&bufs);
sendTo(B, bufs);
receiveFrom(B, &bufr);
selectToKeep(cache, bufr);
```

Passzív szál

```
receiveFromAny(&A, &bufr);
selectToSend(&bufs);
sendTo(A, bufs);
selectToKeep(cache, bufr);
```

selectPeer: A részleges nézetből kiválaszt egy szomszédot.

selectToSend: Az általa ismert szomszédok közül kiválaszt n darabot.

- 1) A megkanott csúcsokat eltárolia lokálisan
- (2) Eltávolítia a többszörösen szereplő csúcsokat.
- (3) A tárolt csúcsok számát *m* darabra csökkenti. Erre

```
Aktív szál
selectPeer(&B);
selectToSend(&bufs);
sendTo(B, bufs);
receiveFrom(B, &bufr);
selectToKeep(cache, bufr);
```

Passzív szál

```
receiveFromAny(&A, &bufr);
selectToSend(&bufs);
sendTo(A, bufs);
selectToKeep(cache, bufr);
```

selectPeer: A részleges nézetből kiválaszt egy szomszédot.

selectToSend: Az általa ismert szomszédok közül kiválaszt n darabot.

- selectToKeep: (1) A megkapott csúcsokat eltárolja lokálisan.
 - (2) Eltávolítja a többszörösen szereplő csúcsokat.
 - (3) A tárolt csúcsok számát *m* darabra csökkenti. Erre
 - többfaita stratégia lehetséges.

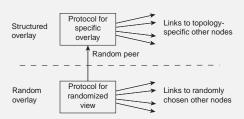
Overlay hálózatok topológiájának kezelése

Alapötlet

Különböztessünk meg két réteget:

- (1) az alsó rétegben a csúcsoknak csak részleges nézete van;
- (2) a felső rétegbe csak kevés csúcs kerülhet.

Az alsó réteg véletlenszerű csúcsokat ad át a felső rétegnek; a felső réteg ezek közül csak keveset tart meg.

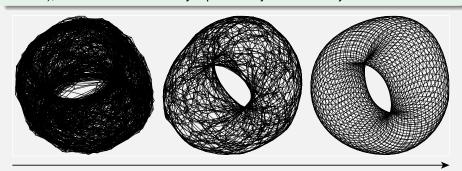


Overlay topológia: példa: tórusz

Tórusz overlay topológia kialakítása

Ha megfelelően választjuk meg, milyen csúcsokat tartson meg a felső réteg, akkor a kezdetben véletlenszerű overlay kapcsolatok hamarosan szabályos alakba rendeződnek.

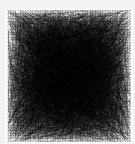
Itt egy távolságfüggvény szerinti megtartó szabály hat (az overlay a közelieket veszi át), és már az első néhány lépés után jól látszik a kijövő tórusz-alakzat.



Time

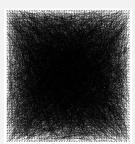
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



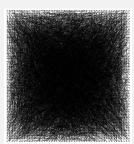
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



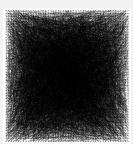
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



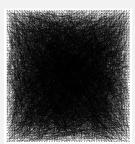
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



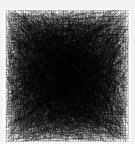
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



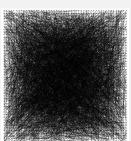
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



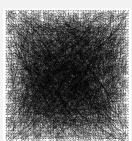
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



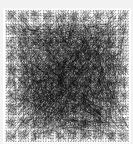
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



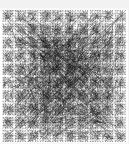
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



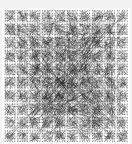
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



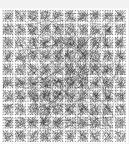
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



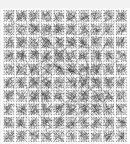
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



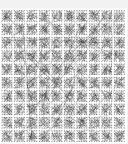
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



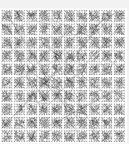
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



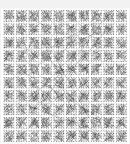
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



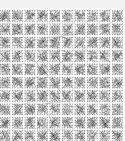
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



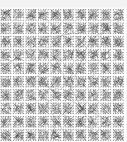
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



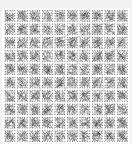
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



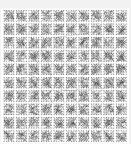
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



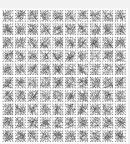
Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$

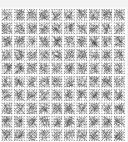


Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$

Most mindegyik i csúcshoz hozzárendelünk egy $GID(i) \in \mathbb{N}$ számot, és azt mondjuk, hogy i a GID(i) csoportba tartozik. Szintén távolságfüggvényt használunk:

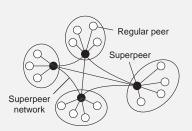
$$dist(i,j) = \begin{cases} 1 & \text{ha } GID(i) = GID(j) \\ 0 & \text{ha } GID(i) \neq GID(j) \end{cases}$$



Superpeer csúcsok

Superpeer

superpeer: olyan kisszámú csúcs, amelyeknek külön feladata van



Néhány jellemző feladat

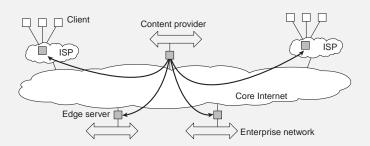
- kereséshez index fenntartása
- a hálózat állapotának felügyelete
- csúcsok közötti kapcsolatok létrehozása

Hibrid arch.: kliens-szerver + P2P: edge szerver

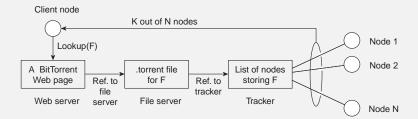
Példa

edge szerver: az adatokat tároló szerver, a kliensekhez minél közelebb van elhelyezve, jellemzően ott, ahol egy nagyobb hálózat az Internetre csatlakozik

Content Delivery Network (CDN) rendszerekben jellemző, a tartalomszolgáltatás hatékonyságát növelik és költségét csökkentik.



Hibrid arch.: kliens-szerver + P2P: BitTorrent



Alapötlet

Miután a csúcs kiderítette, melyik másik csúcsok tartalmaznak részeket a kívánt fájlból, azokat párhuzamosan tölti le, és egyúttal önmaga is kiajánlja megosztásra.

Architektúrák és köztesréteg

Probléma

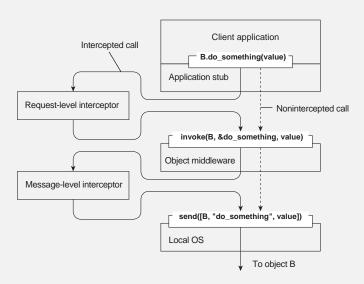
Előfordulhat, hogy az elosztott rendszer/alkalmazás szerkezete nem felel meg a megváltozott igényeknek.

Ilyenkor legtöbbször nem kell újraírni a teljes rendszert: elegendő lehet (dinamikusan) adaptálni a köztesréteg viselkedését.

Interceptor

interceptor: Távoli objektum elérése során a vezérlés szokásos menetébe avatkozik bele, pl. átalakíthatja más formátumra a kérést. Jellemzően az architektúra rétegei közé illeszthető.

Interceptors



Adaptív middleware

2.2 Rendszerarchitektúrák

- Funkciók szétválasztása (separation of concerns): A szoftver különböző jellegű funkciói váljanak minél jobban külön, így azokat könnyebb egymástól függetlenül módosítani.
- Onvizsgálat (reflection): A program legyen képes feltárni a saját szerkezetét, és futás közben módosítani azt.
- Komponensalapú szervezés: Az elosztott alkalmazás legyen moduláris, a komponensei legyenek könnyen cserélhetőek. A komponensek közötti függések legyenek egyértelműek, és csak annyi legyen belőlük, amennyi feltétlenül szükséges.

Önszervező elosztott rendszerek

Adaptív rendszer képességei

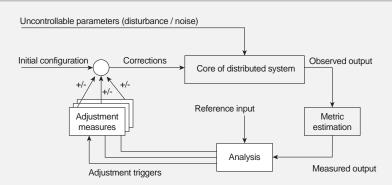
Az egyes szoftverelemek adaptivitása kihat a rendszerre, ezért megvizsgáljuk, hogyan lehet adaptív rendszereket készíteni. Különféle elvárásaink lehetnek:

- Önkonfiguráció
- Önkezelő
- Öngyógyító
- Önoptimalizáló
- Ön*

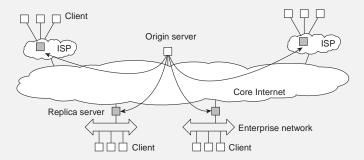
Adaptivitás visszacsatolással

Visszacsatolásos modell

Az ön* rendszerek sokszor az alábbi jellegű visszacsatolásos vezérléssel rendelkeznek: mérik, hogy a rendszer mennyire tér el a kívánt tulajdonságoktól, és szükség szerint változtatnak a beállításokon.



Példa: Globule



- Kollaboratív webes CDN, a tartalmakat költségmodell alapján helyezi el (minden szempontra: fontosság×költség).
- A központi szerver (origin server) elemzi, ami történt, és az alapján állítja be a fontossági paramétereket, hogy mi történt volna, ha P oldalt az S edge szerver tárolta volna.
- A számításokat különböző stratégiákra végzi el, végül a legjobbat választia ki.